



Sieci samooorganizujące się

- ✓ Po raz pierwszy opracowania na temat sieci samoorganizujących z konkurencją i sąsiedztwem pojawiły się w latach 70-tych. Ich autorem był fiński uczony Kohonen – **sieci Kohonena**.
- ✓ Istota uczenia konkurencyjnego (uczenia z rywalizacją, competitive learning)
 - po prezentacji wzorca wejściowego następuje określenie **neuronu wygrywającego** (ang. winner) **i tylko ten neuron, ewentualnie grupa sąsiadujących z nim neuronów aktualizuje swoje wagi, tak by zbliżyć je do aktualnego wzorca.**
 - oczekuje się, że podobne wzorce wejściowe powinny wywoływać podobne odpowiedzi sieci.
- ✓ Decydujący wpływ na sposób funkcjonowania sieci samoorganizującej w trakcie procesu uczenia ma wybór miary odległości wygrywającego neuronu od wektora wejściowego.
 - Każdy neuron (a dokładnie jego wagi) staje się pewnym wzorcem grupy bliskich sobie sygnałów wejściowych, przy czym neurony sąsiadujące ze sobą reprezentują bliskie sobie, podobne obszary przestrzeni wzorców wejściowych.
 - W ten sposób sieć samoorganizująca tworzy topologiczny, zależny od przyjętej metryki, obraz przestrzeni sygnałów wejściowych przeniesiony na wewnętrzną strukturę topologiczną sieci.




- ✓ Najciekawsze efekty uzyskuje się wprowadzając metody Kohonena dla sieci neuronowych dwuwymiarowych,


Topologie sieci



siatka prostokątna



siatka heksagonalna,



łańcuch otwarty



łańcuch


zamknięty.

Linie łączące neurony określają relacje topologiczne.

Każdy neuron jest powiązany z pozostałymi neuronami pewną relacją sąsiedztwa, która określa strukturę sieci.

✓ **Odległości pomiędzy neuronami** można wyznaczyć

- w odniesieniu do metryki zdefiniowanej **w przestrzeni sygnałów wejściowych**,
- **w odniesieniu topologii samej sieci** - pozwala określać sąsiedztwo danego neuronu w postaci zbioru neuronów powiązanych między sobą odpowiednimi relacjami topologicznymi.



✓ Sąsiedztwo rozpatruje się w układach:

- jednowymiarowych, neurony sąsiednie leżą na jednej linii,
- dwuwymiarowych, neurony tworzą siatkę a sąsiadami są neurony położone na lewo i na prawo oraz u góry i u dołu rozpatrywanego neuronu, ewentualnie jeszcze na przekątnych,
- wielowymiarowe, neurony ułożone są swobodnie w przestrzeniach wielowymiarowych, a twórca sieci określa zasady sąsiedztwa.

✓ Istotnym parametrem jest określenie ile neuronów obok (sąsiadów z lewej, prawej itd.) ma podlegać uczeniu w przypadku zwycięstwa danego neuronu.

Miara odległości

- ✓ W procesie samoorganizacji na każdym etapie należy wyłonić zwycięzcę - neuron, którego wektor wagowy różni się najmniej od wektora na wejściu. W tym celu należy dobrać odpowiednią metrykę. Najczęściej używa się

- miary euklidesowej

$$d(\mathbf{x}, \mathbf{w}_i) = \|\mathbf{x} - \mathbf{w}_i\| = \sqrt{\sum_{j=1}^n (x_j - w_{ij})^2}$$

- iloczynu skalarnego

$$d(\mathbf{x}, \mathbf{w}_i) = \sum_{j=1}^n (x_j \cdot w_{ij})$$

- miary według normy L1 (Manhattan)

$$d(\mathbf{x}, \mathbf{w}_i) = \sqrt{\sum_{j=1}^n |x_j - w_{ij}|}$$

- miary według normy L

$$d(\mathbf{x}, \mathbf{w}_i) = \max_j |x_j - w_{ij}|$$

Sieci Kohonena

- ✓ Sieć Kohonena została nazwana przez jego twórcę **samoorganizującym odwzorowaniem** (**Self-Organizing Map - SOM**) lub **samoorganizującym odwzorowaniem cech** (**Self-Organizing Feature Map - SOFM**) i jest najbardziej popularnym typem sieci określanej mianem samoorganizującej.
- ✓ W sieci tej mamy do czynienia z uczeniem konkurencyjnym. Sieć ma na celu utworzenie takiej struktury, która w najlepszy sposób będzie odwzorowywała zależności w przestrzeni wektorów wejściowych.
 - sieć jest zwykle jednokierunkowa,
 - każdy neuron jest połączony ze wszystkimi składowymi N-wymiarowego wektora wejściowego $\mathbf{x}$.
 - wagi połączeń neuronów tworzą wektor $\mathbf{w}_i = [w_{i1}, w_{i2}, \dots, w_{in}]^T$.
 - wektor sygnałów wejściowych $\mathbf{x}$ jest przed procesem uczenia normalizowany $\|\mathbf{x}\|=1$:

$$\hat{\mathbf{x}}_i = \frac{\mathbf{x}_i}{\sqrt{\sum_{k=1}^n \mathbf{x}_k^2}}$$

Adaptacja wag w sieci Kohonena

- ✓ W trakcie uczenia sieci samoorganizujących na wejście każdego neuronu podawany jest n-wymiarowy sygnał $\mathbf{x}$ ze zbioru wzorców uczących
- ✓ We współzawodnictwie zwycięża jeden neuron, którego wagi najmniej różnią się od odpowiednich składowych wektora $\mathbf{x}$.
 - zwycięzca (neuron w-ty) spełnia relację

$$d(\mathbf{x}, \mathbf{w}_w) = \min_{i=1,2,\dots,n} (d(\mathbf{x}, \mathbf{w}_i))$$

- ✓ Wokół zwycięskiego neuronu przyjmuje się topologiczne sąsiedztwo $S_w(n)$, którego promień maleje w czasie.
- ✓ Następnie neuron zwycięzca i neurony sąsiadujące podlegają adaptacji według reguły Kohonena (Kohonen, 1995)

$$w_i(t) = w_i(t-1) + \eta \cdot g(i, \mathbf{x}) \cdot (\mathbf{x} - w_i(t-1))$$

- η – współczynnik uczenia
- $g(i, \mathbf{x})$ – funkcja sąsiedztwa

Sąsiedztwo

- definiuje które neurony, oprócz zwycięskiego, mają zmienić wagi
- może nie być uwzględniane (Winner Takes All)
- musi definiować stopień zmian dla sąsiadów (Winner Takes Most)

✓ W klasycznym algorytmie Kohonena funkcja $g(i, \mathbf{x})$ jest definiowana następująco.

$$g(i, \mathbf{x}) = \begin{cases} 1 & \text{dla } d(i, \mathbf{w}) < \lambda \\ 0 & \text{dla } d(i, \mathbf{w}) \geq \lambda \end{cases}$$

- $d(i, \mathbf{w})$ oznacza odległość euklidesową między neuronem zwycięskim w i i -tym neuronem. Współczynnik jest promieniem sąsiedztwa o wartościach malejących z czasem. Ten typ to sąsiedztwo prostokątne.

✓ Drugim typem sąsiedztwa, z jakim można się spotkać w mapach Kohonena jest sąsiedztwo gaussowskie:

$$g(i, \mathbf{x}) = e^{\frac{-d^2(i, \mathbf{w})}{2\lambda^2}}$$

✓ Sąsiedztwo gaussowskie jest lepsze i prowadzi do lepszych rezultatów uczenia i lepszej organizacji sieci.


Efekty uczenia sieci samoorganizujących

- ✓ Po zakończeniu procesu uczenia, a przed przystąpieniem do pracy należy pamiętać o tym, aby sieć **skalibrować**. Dokonuje tego nauczyciel, podając po jednym sygnale wejściowym z każdej z klas - i opisując który neuron która klasę reprezentuje.
- ✓ Rozmieszczenie wag w przestrzeni tworzy węzły, które połączone z najbliższymi sąsiadami (w sensie sąsiedztwa topologicznego) reprezentują kształt odtwarzający rozkład danych wejściowych.
 - Jest to rozkład odpowiadający gęstości pojawiania się danych wejściowych w danym rejonie a nie współrzędnych odpowiednich wektorów, gdyż liczba prezentowanych wektorów wejściowych jest zwykle o kilka rzędów wyższa niż liczba neuronów w sieci.
- ✓ Liczba neuronów w sieci w praktyce musi być większa od liczby klas sygnałów wejściowych:
 - kilka neuronów może konkurować o reprezentację danej klasy,
 - nadmiarowość powinna zapewnić, iż mniej „lubiane” klasy również będą rozpoznane.

Sieć Counter Propagation - sieć CP

- ✓ Sieć CP stanowi połączenie sieci Kohonena i sieci Grossberga.
- ✓ Z propozycją tej sieci wystąpił Robert Hecht-Nielsen,
- ✓ Jest odpowiedzią na wady sieci ze wsteczną propagacją, gdzie uczenie było powolne i pracochłonne.
- ✓ Ze względu na dość prostą zasadę działania, funkcjonowanie sieci CP porównywane jest do odczytu gotowego wyniku z tablicy.
 - Jej warstwa wejściowa dokonuje adaptacyjnej klasyfikacji sygnałów wejściowych, co pozwala na pewne uogólnianie gromadzonego doświadczenia.

Architektura sieci CP



Przedstawiony rysunek został uproszczony - w rzeczywistym modelu między warstwą Kohonena, a warstwą wyjściową występują połączeniami typu każdy z każdym,

Działanie sieci CP

- ✓ Wektor wejściowy podawany na sieć musi być znormalizowany $||\mathbf{x}||=1$ – ze względu na konkurencyjne uczenia.
- ✓ Element pochodzący z pierwszej warstwy, który jest optymalnie dopasowany do sygnału wejściowego $\mathbf{x}$ przesyłany jest do dalszego przetwarzania w następnej warstwie jako jeden sygnał - "żeton".

rola pierwszej warstwy - warstwy Kohonena

- ✓ W pierwszej warstwie realizowany jest algorytm Kohonena.
 - wyliczany jest potencjał membranowy u_j wszystkich neuronów

$$u_j = \mathbf{w}_j^T \mathbf{x}$$

- Wybierany jest neuron którego pobudzenie jest największe i tylko jego sygnał wyjściowy przyjmuje wartość 1

$$y_j = \begin{cases} 1 & \text{dla } \forall_{i \neq j} u_j > u_i \\ 0 & \text{dla } \forall_{i \neq j} u_j \leq u_i \end{cases}$$

- ✓ Wybrany pojedynczy sygnał - counter jest „żetonem” zastępującym i symbolizującym wszystkie sygnały wejściowe,
- ✓ Sygnał u_j (potencjał membranowy) każdego neuronu w warstwie Kohonena jest miarą podobieństwa pomiędzy sygnałem wektora $\mathbf{x}$, a abstrakcyjnym wzorcem wytrenowanym na j-tym neuronie.
- ✓ Wzorzec idealnego sygnału dla j-tego neuronu zawarty jest w jego wektorze wag $\mathbf{w}_j$.
 - Jeśli $\mathbf{x} = \mathbf{w}_j$, wówczas neuron odpowiada sygnałem o maksymalnej wartości,
 - jeśli $\mathbf{x} \neq \mathbf{w}_j$, wówczas pobudzenie neuronu (u_j) jest miarą cosinusa kąta pomiędzy wektorami $\mathbf{x}$ i $\mathbf{w}_j$.

rola drugiej warstwy - warstwy Outstar Grossberga

- ✓ Druga warstwa sieci realizuje algorytm Outstar Grossberga:

$$\mathbf{y} = \mathbf{v}^T \mathbf{k}$$

- $\mathbf{v}$ - macierz współczynników wagowych
 - $\mathbf{k}$ – wektor wyjść z warstwy Kohonena
- ✓ W praktyce tylko jeden element wektora $\mathbf{k}$ ma wartość 1, a pozostałe mają wartość 0
- ✓ Wystarczy utożsamienie wyjścia y_i z pewnym współczynnikiem wagowym v_{ij} . Działanie takie przypomina odczyt z gotowej tablicy.
 - Na każdym i -tym wyjściu sieci w trakcie procesu uczenia przygotowane zostaje m wariantów odpowiedzi v_{ij} . Gdy warstwa Kohonena ustali, które z jej licznych wyjść otrzyma „żeton” - na wszystkich wyjściach pojawiają się tylko te wartości V_{ij} , które odpowiadają numerowi j , dla którego $k_j = 1$.

Uczenie warstw w CP

- ✓ Uczenie sieci CP przebiega równocześnie w obydwu warstwach sieci.
- ✓ Jest ono typem **uczenia z nauczycielem**, gdyż wraz z każdym wektorem wejściowym $\mathbf{x}$ podawany jest wektor wyjściowy, jaki użytkownik chce uzyskać na wyjściu sieci.
- ✓ W tym przypadku uczenia nie wykorzystujemy pojęcia błędu, co zachodzi przy klasycznym nauczaniu z nauczycielem.
- ✓ Różnicą jest też brak wykorzystania informacji pochodzących od nauczyciela, przy uczeniu pierwszej "ukrytej" warstwy sieci.
- ✓ Zmiany w stosunku do klasycznego nauczania z nauczycielem zostały zastąpione działaniem:
 - przy uczeniu pierwszej warstwy stosuje się technikę Kohonena, która jest formą uczenia bez nauczyciela.
 - przy uczeniu drugiej warstwy wykorzystuje się algorytm Grossberga do bezpośredniego wymuszania pożądaných odpowiedzi sieci

warstwa Kohonena

- ✓ Warstwie Kohonena na t-tym kroku przedstawia się wektor $\mathbf{x}(t)$, a posiadając z wcześniejszego uczenia wartości wektorów, można obliczyć

$$u_j(t) = \mathbf{w}_j^T(t) \mathbf{x}(t)$$

- ✓ Następnie wyznacza się numer zwycięzcy - z
- ✓ Korekcie podlegają wyłącznie wagi "zwycięskiego" neuronu według reguły

$$\mathbf{w}_z(t) = \mathbf{w}_z(t-1) + \eta_1 (\mathbf{x}(t-1) - \mathbf{w}_z(t-1))$$

- ✓ Współczynnik uczenia η_1 przyjmowany jest zwykle jako równy 0,7 na początku procesu uczenia i stopniowo zmniejszany dla większych t.
- ✓ Jak w wielu algorytmach samouczenia, tak samo i tu najważniejsze są pierwsze kroki. Najpierw trzeba nadać współczynnikiem wagowym $\mathbf{w}_{ij}$ wartości początkowe tak, aby były one unormowane.

- ✓ Ważnym krokiem jest takie **dobranie kierunków wektorów wag**, aby w sposób równomierny rozkładały się na powierzchni sfery jednostkowej w przestrzeni n-wymiarowej.
 - Dobranie takich wag jest trudne, ponadto nie zawsze gwarantuje dobre wyniki. Powodem tego może być pojawienie się trakcie uczenia kilku zwycięskich neuronów.
 - Aby zapobiec takiemu zjawisku początkowo wszystkim składowym wszystkich wektorów wag nadaje się tę samą wartość początkową

$$w_{ij}(1) = \sqrt{\frac{1}{n}}$$

- ✓ Powoduje to, że wszystkie wektory wag są prawidłowo unormowane, oraz pokrywają się. Po takiej inicjalizacji zaczyna się proces uczenia z małą różnicą, że jako wektory wejściowe podaje się wektory o współrzędnych obliczanych według wzoru

$$x_i(t) = \eta_2(t) x_i(t) \cdot [1 - \eta_2(t)] \sqrt{\frac{1}{n}}$$

- ✓ Funkcja adaptująca $\eta_2(t)$ dla małych t przyjmuje bardzo małe wartości, natomiast potem rośnie do wartości 1 i tę wartość zachowuje przez resztę procesu uczenia.

Warstwa Grossberga

- ✓ Wagi v_{ij} , w warstwie Grossberga, są zmieniane według reguły Widrowa-Hoffa:

$$\mathbf{v}_{ij}(t) = \mathbf{v}_{ij}(t-1) + \eta_3 (d_i - y_i) k_j$$

- ✓ Ponieważ tylko jedna wartość k_j jest różna od zera i w każdym kroku procesu uczenia korygowane są tylko te wagi, które łączą poszczególne neurony wyjściowej warstwy z jednym tylko "zwycięskim" elementem poprzedniej warstwy. Ta zasada zmniejsza prędkość procesu uczenia.
- ✓ Parametr η_3 wybiera się zazwyczaj ostrożnie, tak aby proces uczenia nie spowodował wpisania do "tablicy" błędnych wartości. Zwykle zaczyna się uczenie od wartości $\eta_3=0,1$, a potem się tę wartość jeszcze mocniej redukuje.

