

Uczenie sieci neuronowych

Etapy życia SSN

- ✓ **Uczenie sieci neuronowej**
- ✓ **Testowanie SSN**
- ✓ **Wykorzystanie SSN do rozwiązywania nauczonego zadania**


Metody uczenia sieci neuronowych

Uczenie sieci polega na automatycznym (według odpowiedniego algorytmu) dobraniu takich wartości wag, przy których sieć będzie możliwie najlepiej rozwiązywała dane zadanie.

- ✓ Rozróżnia się dwa rodzaje uczenia:
 - nadzorowane (z nauczycielem),
 - nienadzorowane (bez nauczyciela).
- ✓ Wagi zawierają całą wiedzę jako posiada neuron (sieć neuronowa)
- ✓ Ogólna zasada nauki przyjęta dla sieci neuronowych brzmi:
wektor wag $\mathbf{w}$ rośnie proporcjonalnie do iloczynu sygnału wejściowego $\mathbf{x}$ i uczącego $\mathbf{r}$


Uczenie nadzorowane

- ✓ Uczenie nadzorowane stosuje się tylko wówczas, gdy istnieje możliwość zweryfikowania poprawności odpowiedzi udzielanych przez sieć; oznacza to, że dla każdego wektora wejściowego musi być znana dokładna postać wektora wyjściowego (pożądana odpowiedź).
- ✓ Schemat postępowania
 - podaj na wejście sieci wektor wejściowy
 - wyznacz błąd popełniany przez sieć
 - wykorzystaj wyznaczony błąd do korekty wag sieci.



Uczenie nienadzorowane

- ✓ Uczenie nienadzorowane stosuje się wówczas gdy nie znamy oczekiwanych odpowiedzi na zadany wzorzec
- ✓ Warunki samouczenia
 - Sygnały wejściowe muszą się dać jakoś sklasyfikować, zasznuflować (muszą być "podobne" do pewnych wzorców tzw. atraktorów)
 - Neuronów musi być wyraźnie więcej, niż atraktorów. Znaczy to, że sieć musi być dostatecznie "mądra", by zaabsorbować pewną dawkę wiedzy.
 - Różnorodne początkowe preferencje poszczególnych neuronów. Jeśli sieć ma się nauczyć rozpoznawania różnych obiektów, musi mieć takie neurony, które mają różne "upodobania".



Kolejność prezentacji wzorców uczących


- ✓ Jak ustalić kolejność prezentacji wzorców?
 - Prezentować dany wzorzec, aż do uzyskania stabilnego wektora wag i następnie przejść do kolejnego wzorca.
 - Prezentować wzorce cyklicznie, w tej samej kolejności.
 - Do każdej prezentacji losować wzorzec - wszystkie wzorce są jednakowo prawdopodobne do wylosowania
- ✓ Najodpowiedniejsza jest metoda trzecia (losowego prezentowania wzorców), gdyż:
 - pierwsza metoda powoduje, iż sieć po wyodrębnieniu danego wzorca traci zdolność rozpoznawania wzorca nauczonego wcześniej,
 - druga metoda może powodować wpadanie sieci w cykl, który nie prowadzi do zbieżności.

Reguły uczenia sieci neuronowych

Wektor wag $\mathbf{w}_i = [w_{i1} \ w_{i2} \ \dots \ w_{in}]^t$ rośnie proporcjonalnie do iloczynu sygnałów wejściowego $\mathbf{x}$ i uczącego r

$$\Delta \mathbf{w}_i(t) = c * r(\mathbf{w}_i(t), \mathbf{x}(t), d_i(t)) * \mathbf{x}(t)$$

Sygnał uczący r jest w ogólności funkcją $\mathbf{w}_i$, $\mathbf{x}$ i czasami sygnału nauczyciela d



$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

y_i – odpowiedź i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący

c – stała uczenia

Reguła Heba

- ✓ Odnosi się do uczenia bez nauczyciela
- ✓ Sygnałem uczącym jest sygnał wyjściowy neuronu

$$r = y_i = f(\mathbf{w}_i^t \mathbf{x})$$

- ✓ Przyrost wektora wag wynosi:

$$\Delta \mathbf{w}_i = c y_i \mathbf{x} = c f(\mathbf{w}_i^t \mathbf{x}) \mathbf{x}$$

- ✓ Pojedyncza składowa wektora wg zmienia się o:

$$\Delta w_{ij} = c y_i x_j$$

- ✓ Wymaga wstępnego ustawienia wag na wartości przypadkowe z otoczenia 0 (zera)

$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

y_i – odpowiedź i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący


c – stała uczenia

Reguła Heba - interpretacja reguły

- ✓ Wzmocnieniu ulegają te wagi, których wejścia są **aktywne** (mają duże **x**) w sytuacji gdy duże jest wzbudzenie neuronu (**y**).
- ✓ Sieć autoasocjacyjna: jeżeli pewien wzór wzbudzenia jest sygnalizowany przez pewne wyjście **y**, to w miarę upływu czasu ta sygnalizacja staje się coraz wyraźniejsza.
- ✓ Reguła prowadzi do uzyskania najlepszej korelacji pomiędzy sygnałami wejściowymi, a zapamiętanym w wagach wzorcem.

Reguła stanowi praktyczną realizację stwierdzenia z zakresu neurologii (Hebb, 1949): *Jeżeli akson komórki A bierze systematycznie udział w pobudzaniu komórki B powodującym jej aktywację, to wywołuje to zmianę metaboliczną w jednej lub w obu komórkach, prowadzącą do wzrostu skuteczności pobudzania komórki B przez komórkę A*

Reguła Heba - przykład



● Krok1:

Wektor x_1 daje łączne pobudzeni u^1 o wartości


$$u^1 = w^{1T} x_1 = [1 \quad -1 \quad 0 \quad 0,5] \begin{bmatrix} 1 \\ -2 \\ 1,5 \\ 0 \end{bmatrix} = 3$$

Przekształcając potencjał membranowy przez funkcję aktywacji otrzymujemy wyjście neuronu:

$$y^1 = f(u^1) = \text{sgn}(3) = 1$$

Które pozwala nam w oparciu o regułę Heba wyznaczyć nowe wartości wag neuronu

$$w^2 = w^1 + cy^1 x_1 = \begin{bmatrix} 1 \\ -1 \\ 0 \\ 0,5 \end{bmatrix} + 1 * 1 * \begin{bmatrix} 1 \\ -2 \\ 1,5 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ -3 \\ 1,5 \\ 0,5 \end{bmatrix}$$



● **Krok2:** Na wejście podajemy wektor x_2


$$u^2 = w^{2T} x_2 = [2 \quad -3 \quad 1,5 \quad 0,5] \begin{bmatrix} 1 \\ -0,5 \\ -2 \\ -1,5 \end{bmatrix} = -0,25$$



$$y^2 = f(u^2) = \text{sgn}(-0,25) = -1$$



$$w^3 = w^2 + cy^2 x_2 = \begin{bmatrix} 2 \\ -3 \\ 1,5 \\ 0,5 \end{bmatrix} - \begin{bmatrix} 1 \\ 0,5 \\ 2 \\ -1,5 \end{bmatrix} = \begin{bmatrix} 1 \\ -2,5 \\ 3,5 \\ 2 \end{bmatrix}$$



● **Krok3:** Na wejście podajemy wektor x_2

$$u^3 = w^{3T} x_3 = \begin{bmatrix} 1 & -2,5 & 3,5 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ -1 \\ 1,5 \end{bmatrix} = -3$$




$$y^3 = f(u^3) = \text{sgn}(-3) = -1$$



$$w^4 = w^3 + cy^3 x_3 = \begin{bmatrix} 1 \\ -2,5 \\ 3,5 \\ 2 \end{bmatrix} - \begin{bmatrix} 0 \\ 1 \\ -1 \\ 1,5 \end{bmatrix} = \begin{bmatrix} 1 \\ -3,5 \\ 4,5 \\ 0,5 \end{bmatrix}$$

Dla dyskretnej (bipolarnej) funkcji aktywacji i $c=1$ uczenie metodą Hebba sprowadza się do dodania lub odjęcia wektora wejściowego do (od) wektora wag

Reguła Heba - przykład



- **Krok1:** Wektor x_1 daje łączne pobudzeni u^1 o wartości

$$u^1 = w^{1T} x_1 = [1 \ -1 \ 0 \ 0,5] \begin{bmatrix} 1 \\ -2 \\ 1,5 \\ 0 \end{bmatrix} \Rightarrow y^1 = f(u^1) = \frac{2}{1 + e^3} - 1 = 0,905 \Rightarrow w^2 = w^1 + cy^1 x_1 = \begin{bmatrix} 1 \\ -1 \\ 0 \\ 0,5 \end{bmatrix} + 0,905 * \begin{bmatrix} 1 \\ -2 \\ 1,5 \\ 0 \end{bmatrix} = \begin{bmatrix} 1,905 \\ -2,81 \\ 1,357 \\ 0,5 \end{bmatrix}$$

- **Krok2:** Na wejście podajemy wektor x_2

$$y^2 = f(u^2) = -0,077 \Rightarrow w^3 = w^2 + cy^2 x_2 = \begin{bmatrix} 1,828 \\ -2,772 \\ 1,512 \\ 0,616 \end{bmatrix}$$

- **Krok3:** Na wejście podajemy wektor x_3

$$y^3 = f(u^3) = -0,905 \Rightarrow w^4 = w^3 + cy^3 x_3 = \begin{bmatrix} 1,828 \\ -3,70 \\ 2,44 \\ -0,783 \end{bmatrix}$$

Dla ciągłej funkcji aktywacji tylko ułamek wzorca wejściowego zwiększa lub zmniejsza wektor wag. Korekcja wag jest więc łagodniejsza, ale zachodzi zasadniczo w tym samym kierunku.

Reguła Heba - cechy, wady i zalety

- ✓ SN skutecznie sama organizuje sygnały wejściowe w klastry.
- ✓ Silnie zależy od wylosowanych na początku procesu uczenia wag. Wartości te wpłyną na podział na klasy. (Jeżeli początkowe wartości wag oznaczają wrodzone skłonności sieci, to będą się one pogłębiały podczas uczenia.)
- ✓ Liczba neuronów w warstwie wyjściowej powinna być większa od liczby klas.
- ✓ Nie wiemy, który neuron będzie odpowiedzialny za rozpoznanie konkretnej klasy (np.. przy rozpoznawaniu liter).
- ✓ Może się zdarzyć, że żaden neuron nie nauczy się rozpoznawania jednej z klas.
- ✓ Wagi rosną bez ograniczenia.
- ✓ Duża wrażliwość na szумы.

Reguła perceptronowa

✓ Dotyczy nauki z nauczycielem i odnosi się do sieci z neuronami dyskretnymi

✓ Sygnałem uczącym jest popełniany błąd

Rosenblat 1958

$$r = d_i - y_i$$

✓ Korekcja wag odbywa się wg zależności

$$\Delta \mathbf{w}_i = c(d_i - \text{sgn}(\mathbf{w}_i^t \mathbf{x})) \mathbf{x}$$

✓ Wartości początkowe wag powinny być losowe.

$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

y_i – odpowiedź i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący

c – stała uczenia

Reguła delta

Reguła delty jest wynikiem minimalizacji sumy kwadratów błędów

- ✓ Odnosi się do uczenia nadzorowanego i obowiązuje dla neuronów z ciągłymi funkcjami aktywacji

- ✓ Sygnał uczący jest zdefiniowany jako:

McClelland, Rumelhart, 1986

$$r = \delta \stackrel{\text{def}}{=} [d_i - f(\mathbf{w}_i^t \mathbf{x})] f'(\mathbf{w}_i^t \mathbf{x})$$

- ✓ Wzór na korekcję wag ma postać:

$$\Delta \mathbf{w}_i = c(d_i - y_i) f'(\mathbf{w}_i^t \mathbf{x}) \mathbf{x}$$

- ✓ Wartości początkowe wag powinny być losowe.

Regułę można uogólnić na przypadek sieci wielowarstwowych

$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

y_i – odpowiedź i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący

c – stała uczenia

Jacek Bartman

Reguła Widrowa-Hoffa (reguła LMS)

Reguła Widrowa-Hoffa jest wynikiem minimalizacji błędu średniokwadratowego

- ✓ Odnosi się do uczenia z nauczycielem sieci o neuronach z dowolną funkcją aktywacji

- ✓ Sygnał uczący jest zdefiniowany jako:

Widrow, 1962

$$\stackrel{\text{def}}{r} = d_i - \mathbf{w}_i^t \mathbf{x}$$

$$r = d_i - u_i$$

- ✓ Korekta wektora wag ma postać

$$\Delta \mathbf{w}_i = c(d_i - \mathbf{w}_i^t \mathbf{x}) \mathbf{x}$$

$$\Delta \mathbf{w}_i = c(d_i - u_i) \mathbf{x}$$

- ✓ Wartości początkowe wag powinny być losowe.

$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

u_i – potencjał i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący

c – stała uczenia

Reguła korelacyjna

- ✓ Odnosi się do uczenia z nauczycielem sieci o neuronach z dowolną funkcją aktywacji

- ✓ Sygnał uczący jest zdefiniowany jako:

$$r = d_i$$

- ✓ Korekta wektora wag ma postać

$$\Delta \mathbf{w}_i = c d_i \mathbf{x}$$

- ✓ Reguła jest analogią do reguły Hebba (uczenia nienadzorowanego $\rightarrow d_i = y_i$)

$\mathbf{x}$ – wektor wejściowy

$\mathbf{w}_i$ – wektor wag i-tego neuronu

y_i – odpowiedź i-tego neuronu

d_i – oczekiwana odpowiedź i-tego neuronu

r – sygnał uczący

c – stała uczenia

Reguła „wygrywający bierze wszystko” (WTA)

- ✓ Odnosi się do uczenia bez nauczyciela (grupa uczenia z rywalizacją)

- ✓ Korekta wektora wag ma postać


$$\Delta \mathbf{w}_i = \alpha (\mathbf{x} - \mathbf{w}_i)$$

$\alpha > 0$ – współczynnik malejący w miarę postępu uczenia


i – numer wygrywającego neuronu ustalony z kryterium

$$\mathbf{w}_i^t \mathbf{x} = \max_{k=1,2..p} (\mathbf{w}_k^t \mathbf{x})$$

- ✓ „Neuron wygrywający” może być rozszerzony na sąsiadów.
- ✓ Wartości początkowe wag są losowe, w kolejnych krokach poddaje się je normalizacji.



Reguła gwiazdy wyjść (outstar)



✓ Odnosi się do uczenia z nauczycielem

✓ Korekta wektora wag ma postać

$\beta > 0$ współczynnik malejący w miarę postępu uczenia

Grosberg, 1977

$$\Delta \mathbf{w}_j = \beta (\mathbf{d} - \mathbf{w}_j)$$