

SZTUCZNA INTELIGENCJA

**Zrealizować sieć radialną uczącą się
rozpoznawania rodzaju wina**

Damian Komoński

2EFDI, L4

Rzeszów 2016

SPIS TREŚCI

Opis projektu	3
Informacje na temat sieci neuronowej	4
Neuron	4
Model neuronu McCullocha-Pittsa	5
Architektura radialnej sieci neuronowej	6
Podstawy matematyczne	8
Struktura RBF	10
Przygotowanie danych	12
Skrypt.....	13
Eksperymenty	15
Podsumowanie	15
Bibliografia.....	15

Opis projektu

Projekt ma na celu stworzenie radialnej sieci neuronowej, która z otrzymanych danych będzie w stanie rozpoznać jeden z trzech rodzajów wina.

Źródło danych:

<http://archive.ics.uci.edu/ml/datasets/Wine>

Dostarczone dane pochodzą z **Instytutu Farmaceutyki i Analizy Żywności Via Brigata Salerno w Genoa (Włochy)** od **Stefan Aeberhard** i są rezultatem chemicznej analizy wzrostu winogrona w tym samym regionie, we Włoszech, lecz pochodzący z trzech różnych upraw. Analiza ustala ilość 13 składników – odnalezionych w każdym z trzech typów winogrona. Autor zamieszcza również informacje o tym, iż początkowo analiza zawierała 30 zbadanych składników, lecz zostały one zagubione.

Wino – napój alkoholowy uzyskiwany w wyniku fermentacji alkoholowej moszczu winogronowego. Moszcz winogronowy z winogron dojrzałych zawiera ilość cukru dostateczną do otrzymania wina o odpowiedniej mocy, zapewniającej mniejszą lub większą trwałość wina.¹

Posiadane atrybuty są następujące:

- 1) Alcohol (tłum. Alkohol)
- 2) Malic acid (tłum. Kwas jabłkowy)
- 3) Ash (tłum. Popiół / Jesion)
- 4) Alcalinity of ash (tłum. Zasadowość popiołu)
- 5) Magnesium (tłum. Magnez)
- 6) Total phenols (tłum. Całkowita zawartość Fenolu)
- 7) Flavanoids (tłum. Flawonoidy – naturalny barwnik)
- 8) Nonflavanoid phenols (tłum. Nienaturalny Fenol)
- 9) Proanthocyanins
- 10) Color intensity (tłum. Intensywność koloru)

¹ <https://pl.wikipedia.org/wiki/Wino>

11) Hue (tłum. Odcień)

12) OD280/OD315 of diluted wines (tłum. OD280/OD315 rozcieńczonego wina)


13) Proline (tłum. Prolina)

Informacje na temat sieci neuronowej

Sieć neuronowa to ogólna nazwa struktur matematycznych i ich programowych lub sprzętowych modeli, które realizują obliczenia lub przetwarzają sygnały. Wykonują to poprzez rzędy elementów, zwanymi **sztucznymi neuronami**, które wykonują pewną podstawową operację na swoim wejściu. Inspiracją do budowy takiej struktury był po prostu nasz mózg.

Neuron

Jego schemat został opracowany przez McCullocha i Pittsa w 1943r. i oparty na budowie komórki nerwowej.




Rysunek nr. 1 – Uproszczony schemat komórki nerwowej

Jego działanie polega na tym, że to wejść doprowadzane są sygnały dochodzące z neuronów warstwy poprzedniej. Każdy sygnał mnożony jest przez odpowiadającą mu wagę. Wpływa ona na percepcję danego sygnału wejściowego i jego udział w tworzeniu sygnału wyjściowej

przez neuron. Waga może być **pobudzająca** (*dodatnia*) lub **opóźniająca** (*ujemna*). W sytuacji, gdy nie ma połączenia między neuronami to waga jest równa zero. Zsumowane iloczyny sygnałów i wag stanowią argument funkcji aktywacji systemu.

Model neuronu McCullocha-Pittsa

W modelu neuronu McCullocha-Pittsa przyjęto jako jednostkę binarną [116,167].



Rysunek nr. 2 – Schemat modelu neuronu Pittsa

Sygnały wejściowe x_j ($j = 1, 2, \dots, N$) są sumowane z odpowiednimi wagami w_{ij} (sygnał przepływa w kierunku od węzła j do węzła i) w sumatorze, a następnie porównywane z progiem w_{i0} . Sygnał wyjściowy neuronu y_i wyraża się wówczas zależnością:

$$y_i = f\left(\sum_{j=1}^N w_{ij} x_j(t) + w_{i0}\right)$$

Argumentem funkcji jest sygnał sumacyjny

$$u_i = \sum_{j=1}^N w_{ij} x_j(t) + w_{i0}$$

Funkcja $f(u_i)$ jest zwana funkcją aktywacji. W tym modelu jest to funkcja skokowa.

$$f(u) = \begin{cases} 1, & u > 0 \\ 0, & u \leq 0 \end{cases}$$

Współczynniki w_{ij} występujące we wzorze reprezentują wagę połączeń synaptycznych. Wartość w_{ij} dodatnia oznacza synapsę pobudzającą, ujemna – hamującą, natomiast $w_{ij}=0$ świadczy o braku połączenia między i-tym a j-tym neuronem.

Model McCullocha-Pittsa jest modelem dyskretnym, w którym stan neuronu w chwili **(k+1)** określany jest na podstawie stanu sygnałów wejściowych neuronów w chwili poprzedniej **k**. Przyjęcie modelu dyskretnego jest uzasadnione występowaniem zjawiska refrakcji w rzeczywistej komórce neuronowej, które powoduje, że neuron może zmieniać swój stan z pewną ograniczoną częstotliwością, przy występowaniu stref nieczułości, regulowanych przez częstotliwość próbkowania.

Architektura radialnej sieci neuronowej

Jednym z komplementarnych sposobów odwzorowania zbioru wejściowego w wyjściowy jest odwzorowanie przez dopasowanie wielu pojedynczych funkcji aproksymujących do wartości zadanych, ważne jedynie w wąskim obszarze przestrzeni wielowymiarowej. W takim rozwiązaniu odwzorowanie pełnego zbioru danych jest sumą odwzorowań lokalnych. Z uwagi na rolę, jaką pełnią neurony ukryte, stanowią one zbiór funkcji bazowych typu

lokalnego. Oddziaływanie pojedynczych funkcji (*niezerowe wartości*) obserwuje się jedynie w wąskim obszarze przestrzeni danych – stąd nazwa aproksymacji lokalnej.

Specjalną odmianę stanowią sieci o **radialnej funkcji bazowej**, w której neuron ukryty realizuje funkcję zmieniającą się radialnie wokół wybranego centrum $\mathbf{c}$ i przyjmującą wartości niezerowe tylko w otoczeniu tego centrum.

Funkcje takie oznaczane ogólnie w postaci:


$$\varphi(\mathbf{x}) = \varphi(\|\mathbf{x} - \mathbf{c}\|)$$

nazywane będą **radialnymi funkcjami bazowymi**. Rola neuronu ukrytego będzie się sprowadzać w takich sieciach do odwzorowania radialnego przestrzeni wokół jednego punktu zadanego lub grupy takich punktów stanowiących **klaster**. Superpozycja sygnałów pochodzących od wszystkich neuronów ukrytych, dokonywana przez neuron wyjściowy, pozwala uzyskać odwzorowanie całej przestrzeni wielowymiarowej.

Sieci typu radialnego stanowią naturalne uzupełnienie sieci sigmoidalnych. Neuron sigmoidalny reprezentuje w przestrzeni wielowymiarowej hiperpłaszczyznę separującą tę przestrzeń na dwie kategorie (klasy), w których spełnione jest odpowiedni warunek:

$$\text{albo } \sum_j w_{ij} x_j > 0, \text{ albo } \sum_j w_{ij} x_j < 0.$$

Ilustrację takiego podziału przestrzeni przedstawiono na poniższym rysunku. Neuron radialny z kolei reprezentuje hipersferę, dokonującą separacji kołowej wokół punktu centralnego.



Rysunek nr. 3 – Sposób separacji przestrzeni danych przez a) neuron sigmoidalny, b) neuron radialny

Typowa sieć radialna jest strukturą zawierającą warstwę wejściową, do której przykładane są sygnały opisane wektorem wejściowym $\mathbf{x}$, warstwę ukrytą o neuronach typu radialnego i warstwę wyjściową, zwykle złożoną z jednego lub większej liczby neuronów liniowych. Rola

neuronu wyjściowego sprowadza się jedynie do sumowania wagowego sygnałów pochodzących od neuronów ukrytych.

Podstawy matematyczne

Podstawę matematyczną funkcjonowania sieci radialnych stanowi twierdzenie T. Covera o separowalności wzorców. Najprostsza sieć neuronowa typu radialnego działa na zasadzie **wielowymiarowej interpolacji**, której zadaniem jest odwzorowanie p równych wektorów wejściowych $\mathbf{x}_i$ ($i=1,2,\dots,p$) z przestrzeni wejściowej N -wymiarowej w zbiór p liczb rzeczywistych d_i ($i=1,2,\dots,p$).

Przyjęcie p neuronów ukrytych połączonych wagami $\mathbf{w}_i$ z neuronami wyjściowymi (liniowymi) tworzy sygnał wyjściowy jako sumę wagową poszczególnych funkcji bazowych.

$$F(\mathbf{x}_i) = d_i, \quad i = 1, 2, \dots, p$$

Układ równań liniowych względem wag możemy zapisać:

$$\begin{bmatrix} \varphi_{11} & \varphi_{12} & \dots & \varphi_{1p} \\ \varphi_{21} & \varphi_{22} & \dots & \varphi_{2p} \\ \dots & \dots & \dots & \dots \\ \varphi_{p1} & \varphi_{p2} & \dots & \varphi_{pp} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \dots \\ w_p \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \dots \\ d_p \end{bmatrix}$$

gdzie $\varphi_{ji} = \varphi(\|\mathbf{x}_j - \mathbf{x}_i\|)$ dotyczy funkcji radialnej w centrum $\mathbf{x}_i$ przy wektorze wymuszającym $\mathbf{x}_j$

$$\Phi \mathbf{w} = \mathbf{d}, \rightarrow \mathbf{w} = \Phi^{-1} \mathbf{d}$$

Podobnie jak w sieciach wielowarstwowych redukuje się wagi, w przypadku sieci radialnych następuje redukcja liczby funkcji bazowych. Przy ograniczeniu się do K funkcji bazowych rozwiązanie można przedstawić:

$$F(x) = \sum_{i=1}^K w_i \varphi(\|x - c_i\|)$$

gdzie $K < p$

$c_i - (i=1,2,\dots,K)$ jest zbiorem centrów które trzeba wyznaczyć

Podczas doboru funkcji radialnych oraz wartości wag można je sprowadzić do minimalizacji funkcji celu:

$$E = \sum_{i=1}^p \left[\left(\sum_{j=1}^K w_j \varphi(\|x_i - c_j\|) - d_i \right)^2 \right]$$

gdzie K – liczba neuronów radialnych, p – liczba par uczących

Macierz radialna G zwana **macierzą Greena**

$$G = \begin{bmatrix} \varphi(\|x_1 - c_1\|) & \varphi(\|x_1 - c_2\|) & \dots & \varphi(\|x_1 - c_K\|) \\ \varphi(\|x_2 - c_1\|) & \varphi(\|x_2 - c_2\|) & \dots & \varphi(\|x_2 - c_K\|) \\ \dots & \dots & \dots & \dots \\ \varphi(\|x_p - c_1\|) & \varphi(\|x_p - c_2\|) & \dots & \varphi(\|x_p - c_K\|) \end{bmatrix}$$

Przy założeniu znajomości parametrów funkcji radialnych problem sprowadza się tak naprawdę do rozwiązania układu liniowego.

$$\mathbf{G} \mathbf{w} = \mathbf{d} \rightarrow \mathbf{w} = \mathbf{G}^+ \mathbf{d}$$

Natomiast macierz skalująca przy $\mathbf{N}$ wymiarowym wektorze $\mathbf{x}$ ma postać:

$$Q = \begin{bmatrix} Q_{11} & Q_{12} & \dots & Q_{1N} \\ Q_{21} & Q_{22} & \dots & Q_{2N} \\ \dots & \dots & \dots & \dots \\ Q_{N1} & Q_{N2} & \dots & Q_{NN} \end{bmatrix}$$


Struktura RBF

Najczęściej używana postać funkcji radialnej to **funkcja Gaussa**, przy założeniu jej centrum w punkcie $\mathbf{c}_i$

$$\varphi(x) = \varphi(\|x - c_i\|) = \exp\left(-\frac{\|x - c_i\|^2}{2\sigma_i^2}\right)$$

W przypadku gaussowskiej postaci funkcji radialnej związanej z i -tą funkcją bazową dostaje się postać:

$$\begin{aligned} \varphi(x) &= \varphi(\|x - c_i\|_{Q_i}) = \exp\left[-(x - c_i)^T Q_i^T Q_i (x - c_i)\right] = \\ &= \exp\left[-\frac{1}{2}(x - c_i)^T C_i (x - c_i)\right] \end{aligned}$$



Rysunek nr. 4 – Ogólna postać sieci radialnej RBF


Architektura sieci radialnych jest analogiczna do wielowarstwowych sieci sigmoidalnych, występują jednak pewne różnice:

- Sieć radialna ma strukturę ustaloną w jednej warstwie ukrytej i liniowych neuronach wyjściowych
- Większe zróżnicowanie w doborze kształtu – sieć radialna
- Nieliniowa funkcja radialna dla każdego neuronu ukrytego ma inne parametry $\mathbf{C}_i$ oraz σ_i
- Argumentem funkcji radialnej jest euklidesowa odległość danej próbki $\mathbf{X}$ od centrum $\mathbf{C}_i$

Przygotowanie danych

Dane zostały pobrane ze strony <http://archive.ics.uci.edu/ml/datasets/Wine> Pobrany zestaw danych składał się z 14 kolumn i 178 wierszy. Wszystkie wartości w zestawie danych były dodatnie.

Kolumna pierwsza zawierała macierz wynikową w której znalazły się tylko liczby 1,2 lub 3.



	1	2	3	4	5	6	7	8	9	10	11
1	14.23	13.2	13.16	14.37	13.24	14.2	14.39	14.06	14.83	13.86	
2	1.71	1.78	2.36	1.95	2.59	1.76	1.87	2.15	1.64	1.35	
3	2.43	2.14	2.67	2.5	2.87	2.45	2.45	2.61	2.17	2.27	
4	15.6	11.2	18.6	16.8	21	15.2	14.6	17.6	14	16	
5	127	100	101	113	118	112	96	121	97	98	
6	2.8	2.65	2.8	3.85	2.8	3.27	2.5	2.6	2.8	2.98	
7	3.06	2.76	3.24	3.49	2.69	3.39	2.52	2.51	2.98	3.15	
8	0.28	0.26	0.3	0.24	0.39	0.34	0.3	0.31	0.29	0.22	
9	2.29	1.28	2.81	2.18	1.82	1.97	1.98	1.25	1.98	1.85	
10	5.64	4.38	5.68	7.8	4.32	6.75	5.25	5.05	5.2	7.22	
11	1.04	1.05	1.03	0.86	1.04	1.05	1.02	1.06	1.08	1.01	
12	3.92	3.4	3.17	3.45	2.93	2.85	3.58	3.58	2.85	3.55	
13	1065	1050	1185	1480	735	1450	1290	1295	1045	1045	
14											
15											
16											
17											
18											

Rysunek nr. 5 – Przykładowy wycinek danych (macierz już odwrócona)

Dane zostały znormalizowane w celu uzyskania większej dokładności wyników.

[rysunek danych znormalizowanych]

[wykres]

Skrypt

```
%czyszczenie ekranu
clear all

%macierz wynikowa
wyniki=zeros(3000,3);

%zmienna potrzebna do inkrementacji w petli w celu zapisu wynikow
liczba=0;

%wczytanie pliku z danymi wina
load wine.txt

%wczytanie macierzy wektorów wyjsciowych
T=wine(:, 1)';

%wczytanie macierzy wektorów wejsciowych
disp('/***** Dane przed normalizacja:
*****/')
P=wine(:, 2:14)'

%wykonanie normalizacji danych wejściowych
ymax = 1;
ymin = -1;
pmax = max(P');
pmin = min(P');
Pn = zeros(size(P));
for i=1:length(pmax)
    Pn(i,:) = (ymax-ymin)/(pmax(i)-pmin(i))*(P(i,:)-pmin(i))+ymin;
end
disp('/***** Dane po normalizacji:
*****/')
Pn

%stała rozrzutu RBF
```

```

sc = [0.01:0.1:10];

%liczba neuronów
mn = [10:10:200];

%błąd średniokwadratowy (błąd / liczba zbadanych win)
mse = 0.25 / 187;

%proces uczenia
for mn_iterator=1:length(mn)
    for sc_iterator=1:length(sc)

        %inkrementacja zmiennej potrzebnej do zapisu wynikow
        liczba=liczba+1;

        %nowa sieć
        net = newrb(Pn, T, mse, sc(sc_iterator), mn(mn_iterator));

        %wyjście sieci
        A=sim(net,Pn);

        %zapis wyników sc i mn
        wyniki(liczba,1)=sc(sc_iterator);
        wyniki(liczba,2)=mn(mn_iterator);

        %zapis wskaźnika poprawności
        wyniki(liczba,3)=(1-sum(abs(T-A)>0.5)/length(T))*100;

    end;
end;

disp('koniec')

```

Eksperymenty

...

Podsumowanie

....

Bibliografia

...